Zhoda pracovných pozícií a zručností

Semantické vyhľadávanie a hodnotenie typov zručností v úlohe TalentCLEF 2026 Task B

Tím projektu

25. október 2026

Abstrakt

Táto práca sa zaoberá úlohou TalentCLEF 2026 Task B, ktorej cieľom je vyhľadať zručnosti relevantné pre názov pracovnej pozície a zoradiť ich podľa relevantnosti. Zároveň úloha rozlišuje medzi základnými zručnosťami (*core*) a kontextovými zručnosťami (*contextual*). Navrhli sme reprodukovateľný experimentálny pipeline založený na sentence-embedding modeloch, kosínovej podobnosti, reprezentácii ESCO zručností pomocou aliasov a kontrastívnom fine-tuningu vybraných modelov. Porovnali sme päť predtrénovaných modelov a tri stratégie spracovania aliasov. Najlepší výsledok podľa graded nDCG dosiahol model `TechWolf/JobBERT-v2` bez fine-tuningu, pri priemerovaní embeddingov všetkých aliasov zručnosti ($nDCG = 0{,}7381$). Fine-tuning zlepšil všeobecné modely E5 a MPNet, zatiaľ čo pri JobBERT zlepšil najmä presnosť v horných pozíciách. Podľa dostupných qrels modely lepšie oddeľujú posudzované relevantné položky od nepozitívnych alebo nehodnotených kandidátov než zoradia základné a kontextové zručnosti.

Kľúčové slová: spracovanie prirodzeného jazyka, sentence embeddings, ESCO, vyhľadávanie zručností, ranking, TalentCLEF, JobBERT

1 Problém, motivácia a ciele

Digitálne pracovné portály, nástroje na odporúčanie pracovných ponúk a systémy na analýzu trhu práce potrebujú prepájať neštruktúrovaný text pracovných ponúk s jednotným opisom profesií a zručností. Rovnaká zručnosť môže byť v texte vyjadrená rôznymi synonymami a názov pracovnej pozície často neposkytuje dostatočne podrobný zoznam požiadaviek. Ručné mapovanie pozícií na zručnosti je časovo náročné, ťažko škálovateľné a môže byť nekonzistentné medzi anotátormi alebo organizáciami.

TalentCLEF 2026 Task B formalizuje tento problém ako vyhľadávanie zručností pre názov pracovnej pozície a klasifikáciu typu nájdenej zručnosti [1]. V kontexte úlohy je základná zručnosť potrebná na výkon práce bez ohľadu na konkrétneho zamestnávateľa alebo pracovné prostredie. Kontextová zručnosť závisí viac od organizácie, odvetvia alebo projektu a má preto voliteľnejší charakter.

Motiváciou projektu je vytvoriť systém, ktorý:

1. automaticky vyhľadá zručnosti relevantné pre názov pozície;
2. využije normalizovaný slovník ESCO namiesto voľného generovania názvov;

3. zoradí zručnosti tak, aby sa relevantné položky nachádzali na začiatku;
4. vyhodnotí rozdiel medzi základnou a kontextovou relevanciou prostredníctvom graded rankingu;
5. bude reprodukovateľný a vyhodnotený na oficiálnom development formáte.

Projekt skúma tieto výskumné otázky:

VO1: Ako dobre dokážu predtrénované sentence-embedding modely vyhľadávať ESCO zručnosti pre názov pozície?

VO2: Zlepšuje doménová špecializácia modelu výsledky oproti všeobecným embedding modelom?

VO3: Pomáha pri reprezentácii zručnosti použiť všetky jej aliasy?

VO4: Zlepšuje kontrastívny fine-tuning vybraných modelov retrieval?

VO5: Sú modely úspešnejšie pri rozlíšení relevantnej a irelevantnej zručnosti než pri zoradení základných a kontextových zručností?

2 Súvisiaca práca

2.1 TalentCLEF a ESCO

TalentCLEF rozširuje klasické úlohy informačného vyhľadávania o doménu ľudského kapitálu a pracovných zručností. Prehľad súťaže opisuje spoločné úlohy, dáta a hodnotenie a zdôrazňuje potrebu normalizovaných znalostí o pracovných pozíciách a zručnostiach [2]. Špecifický prehľad Task B definuje párovanie názvov pozícií so zručnosťami a graded relevanciu, v ktorej sa rozlišujú základné a kontextové zručnosti [1].

ESCO predstavuje európsku viacjazyčnú klasifikáciu zručností, kompetencií, kvalifikácií a povolaní. V tomto projekte sa využívajú ESCO identifikátory a textové termíny zručností. Identifikátor umožňuje, aby sa synonymné alebo alternatívne pomenovania spájali s jednou normalizovanou položkou.

2.2 Prístupy účastníkov

Predchádzajúce riešenia v rámci TalentCLEF kombinujú lexikálne, neurónové a hybridné retrieval metódy. Práca MARSAD opisuje ESCO-aware hybridné vyhľadávanie, v ktorom sa kombinuje informácia zo štruktúry ESCO a textová podobnosť [3]. Tento smer je relevantný pre náš projekt, pretože ukazuje, že samotná povrchová podobnosť nemusí zachytiť vzťahy medzi pozíciami a zručnosťami.

Tím ui-nlp používa bi-encoder retrieval a ensemble stratégie pre úlohy job-person a job-skill matching [4]. Bi-encoder prístup je blízky nášmu pipeline: dotazy a kandidátne dokumenty sa kódujú samostatne a následne sa porovnávajú vo vektorovom priestore. Výhodou je škálovateľnosť na tisíce kandidátnych zručností; nevýhodou je, že samostatné embeddingy nemusia zachytiť všetky jemné interakcie medzi dvojicou textov.

Naše riešenie preto používa sentence embeddings ako transparentný a reprodukovateľný baseline. Rozširuje ho porovnaním doménového modelu JobBERT, všeobecných modelov a kontrastívneho fine-tuningu. Nejde o generovanie nových zručností: všetky výsledky sa vyberajú z poskytnutého ESCO-normalizovaného corpus.

3 Dáta

3.1 Pôvod a formát

Použité dáta pochádzajú z adresára `data/raw/TaskB`. Tréningová časť obsahuje vzťahy medzi povolaniami a zručnosťami odvodené z ESCO a dve mapovania identifikátorov na textové termíny. Development časť obsahuje dotazy, úplný slovník kandidátnych zručností a súbor qrels s anotovanou relevanciou.

V tejto práci používame nasledujúce pojmy:

Povolanie (occupation): identifikované ESCO URI alebo tréningovým `job_id`; jeho textové pomenovanie je názov pozície.

Zručnosť (skill): ESCO položka identifikovaná URI alebo `skill_id`.

Alias: alternatívny textový názov tej istej ESCO zručnosti.

Query: názov pracovnej pozície, pre ktorú sa vyhľadávajú zručnosti.

Corpus item: kandidátna ESCO zručnosť, ktorú možno zaradiť do výsledného zoznamu.

Qrel: judgment vzťahu query–corpus item. Obsahuje query ID, corpus ID a graded relevanciu.

Tabuľka 1: Počty záznamov v použitých dátových súboroch.

Súbor	Počet	Význam
`training/job2skill.tsv`	114 699	tréningové väzby povolanie–zručnosť
`training/jobid2terms.json`	3 039	top-level identifikátory povolaní
`training/skillid2terms.json`	13 939	top-level identifikátory zručností
`validation/queries`	304	development query názvov pozícií
`validation/corpus_elements`	9 052	kandidátne ESCO zručnosti
`validation/qrels.tsv`	56 418	anotované query–skill judgments
`processed/train.csv`	164 699	páry po pridaní vzorkovaných negatívov
`processed/test.csv`	96 418	lokálny validation-derived súbor

Počty v tabuľke predstavujú fyzické dátové záznamy. JSON súbory obsahujú 3 039, respektíve 13 939 top-level identifikátorov; po spojení s tréningovým mappingom môže byť počet aktívne prepojených identifikátorov menší, čo však nie je alternatívna definícia počtov uvedených v tabuľke. Pri súboroch TSV `job2skill.tsv` a `qrels.tsv` nejde o riadok s hlavičkou. Pri spracovaní sa k pozitívnym riadkom pridajú textové názvy a následne sa do CSV doplnia syntetické negatívy. Preto má `processed/train.csv` $114\,699 + 50\,000 = 164\,699$ dátových riadkov a `processed/test.csv` $56\,418 + 40\,000 = 96\,418$ dátových riadkov; CSV hlavička sa do týchto počtov nezapočítava. Qrels explicitne obsahuje grade 2 pre core zručnosti a grade 1 pre contextual zručnosti. Kandidátne skills, ktoré v qrels chýbajú, dostávajú pri evaluácii grade 0. V qrels je 16 161 záznamov grade 2 a 40 257 záznamov grade 1.

3.2 Licencia a redistribúcia

V pracovnom priestore nie je pri dátových súboroch priložený samostatný licenčný súbor, ktorý by udeľoval všeobecné právo na redistribúciu. Dáta preto neinterpretujeme ako voľne redistribuovateľný dataset. Použitie ESCO údajov a materiálov TalentCLEF musí rešpektovať podmienky organizátorov, podmienky zdroja ESCO a prípadné podmienky konkrétneho kurzu alebo súťaže. Táto správa opisuje lokálny experiment; pred zverejnením dát alebo modelových artefaktov je potrebné overiť aktuálne licenčné a redistribučné pravidlá.

4 Predspracovanie dát

Implementácia predspracovania je v notebooku `data_processing.ipynb`. Na začiatku sa načíta `job2skill.tsv`, mapovanie `jobid2terms.json` a mapovanie `skillid2terms.json`. Z každého zoznamu termínov sa pre lokálny spracovaný súbor vyberie prvý termín ako `job_name`, respektíve `skill_name`. Následne sa obe mapovania spoja s tabuľkou väzieb podľa identifikátorov.

Pôvodné označenia tréningových väzieb sú:

Pôvodné označenie	**Číselný label**	**Interpretácia**
`essential`	2	základná zručnosť
`optional`	1	kontextová/voliteľná zručnosť
`irrelevant`	0	irelevantná dvojica

4.1 Vzorkovanie negatívnych párov

Tréningové mapovanie obsahuje iba známe pozitívne väzby, preto notebook vytvára 50 000 negatívnych párov. Náhodne sa vyberajú povolania a zručnosti zo zoznamov identifikátorov. Dvojica sa prijme iba vtedy, ak sa nenachádza v množine známych pozitívnych dvojíc. Proces opakuje bloky 1 000 náhodných výberov, až kým nevznikne 50 000 unikátnych kandidátov. Seed je nastavený na hodnotu 42 v súbore `config.py`. Páry sa následne spoja s textami a dostanú label 0.

Takto vytvorené negatívy sú *assumed negatives*: ide o dvojice, ktoré nie sú v poskytnutom mappingu, nie o manuálne overené negatívne anotácie. Neprítomnosť väzby preto nemusí znamenať, že zručnosť je v realite pre dané povolanie nesprávna. Toto obmedzenie je dôležité pri interpretácii modelov, ktoré by tieto negatívy používali ako učebné príklady.

Pre validation-derived `test.csv` sa rovnakým postupom pridá 40 000 náhodných negatívnych párov k oficiálnym qrels z development časti. Tento lokálny súbor nie je skrytý oficiálny test súťaže a nepoužíva sa ako hlavný ranking benchmark. Hlavné experimenty pracujú priamo s 304 development queries, úplným corpusom 9 052 skills a qrels.

5 Finálna metodika a experimentálny pipeline

5.1 Spoločný ranking pipeline

Finálny experimentálny pipeline je implementovaný v tomto poradí:

1. `data_processing.ipynb`: príprava tréningových a validation-derived tabuliek;

2. `04_five_model_comparison.ipynb`: porovnanie piatich modelov a troch aliasových stratégií;
3. `05_locked_model_comparison.ipynb`: uzamknutie mean reprezentácie a výber modelov na fine-tuning;
4. `06_finetune_selected_models.ipynb`: fine-tuning JobBERT, E5 a MPNet;
5. `07_final_comparison_and_error_analysis.ipynb`: finálne porovnanie a error analysis.

Spoločný ranking postup v notebookoch 04–07 pozostáva z týchto krokov:

1. načítanie development queries, corpus elements a qrels;
2. zakódovanie názvov pozícií a textov skill aliasov sentence-embedding modelom;
3. vytvorenie reprezentácie každej skill;
4. výpočet kosínovej podobnosti medzi query embeddingom a každou kandidátnou skill;
5. zoradenie všetkých 9 052 kandidátov pre každú z 304 pozícií;
6. porovnanie výsledného poradia s qrels.

Embeddings sa normalizujú, takže kosínová podobnosť je v implementácii ekvivalentná skalárnemu súčinu. Modely neprodukujú nové názvy skills; skóre určuje iba poradie položiek v poskytnutom gazetteer.

5.2 Porovnávané modely

Notebook `04_five_model_comparison.ipynb` porovnáva:

- `all-MiniLM-L6-v2`;
- `all-mpnet-base-v2`;
- `TechWolf/JobBERT-v2`;
- `BAAI/bge-base-en-v1.5`;
- `intfloat/e5-base-v2`.

Pre každú zručnosť sa testujú tri reprezentácie:

first: použije sa iba prvý alias;

mean: embeddingy všetkých aliasov sa spriemerujú a výsledný vektor sa znovu normalizuje;

max: skóre zručnosti je maximum kosínovej podobnosti cez všetky jej aliasy.

Notebook 05 následne *uzamkne* globálnu stratégiu aliasov. Kritériom je priemerný graded nDCG cez všetkých päť modelov; pri zhode sa použije MAP. Výsledkom je stratégia `mean`: 0,6526 oproti 0,6502 pre `first` a 0,6426 pre `max`. Na základe poradia modelov pri uzamknutej reprezentácii sa na fine-tuning vyberú JobBERT, E5 a MPNet.

Rozsah implementovanej úlohy. Projekt implementuje retrieval s graded relevanciou, nie samostatný trojtriedny klasifikátor. Grade 2 označuje core/essential skill, grade 1 contextual/optional skill a kandidát bez záznamu v qrels dostáva pri evaluácii grade 0. Fine-tuning používa labels 1 a 2 ako pozitívne páry. Rozlíšenie core a contextual sa preto vyhodnocuje nepriamo poradím prostredníctvom graded nDCG. Samostatná classification head, ktorá by predikovala core, contextual, complementary alebo transversal triedu, implementovaná nie je. Širšie termíny complementary a transversal sa v tomto projekte nepoužívajú ako samostatné labely.

5.3 Reprodukovateľnosť experimentálneho pipeline

Projekt poskytuje zdokumentovaný a reprodukovateľný experimentálny postup. Presná numerická reprodukcia však nemusí byť za každých okolností identická v dôsledku verzií softvéru, použitého hardvéru, konfigurácie CUDA, nondeterministického tréningu a opätovného sťahovania modelov. Lokálne fine-tuned checkpointy nie sú súčasťou repozitára. Experimenty používajú `RANDOM_SEED = 42`. Závislosti sú uvedené v `requirements.txt`: `pandas`, `numpy`, `scikit-learn`, `sentence-transformers`, `jupyter`, `datasets`, `accelerate` a `matplotlib`; ich verzie však nie sú úplne pripnuté. Predtrénované modely sa pri prvom spustení načítajú z Hugging Face. Notebooky je potrebné spúšťať z koreňa repozitára, aby relatívne cesty k dátam fungovali.

6 Metriky a experimentálne nastavenie

6.1 Metriky

Implementácia metrík je v súbore `ranking_metrics.py`. Pre každý query sa najprv vytvorí stabilné poradie podľa klesajúceho skóre. Stabilné triedenie zabezpečuje deterministické správanie pri zhodných skóre.

Graded nDCG. Hlavná metrika *graded nDCG* používa zisky 2 pre základné a 1 pre kontextové zručnosti. Diskontovanie podľa pozície znamená, že relevantná zručnosť na začiatku zoznamu je cennejšia než rovnaká zručnosť na jeho konci:

$$DCG = \sum_{i=1}^{n} \frac{rel_i}{\log_2(i+1)}, \qquad nDCG = \frac{DCG}{IDCG}.$$

Táto metrika je vhodná, pretože zohľadňuje retrieval aj rozdiel medzi core a contextual.

Binary nDCG a MAP. Pri binárnych metrikách sa labels 1 a 2 zlúčia do hodnoty relevantné. MAP meria, ako kompaktne sú všetky relevantné položky umiestnené v poradí, nie iba prvá nájdená položka. Binary nDCG a MAP preto hodnotia schopnosť odfiltrovať irelevantné zručnosti.

MRR a Precision@K. MRR používa recipročnú pozíciu prvej relevantnej zručnosti. Precision@1, Precision@5 a Precision@10 merajú priemerný podiel relevantných zručností v horných K pozíciách. Sú praktické pre používateľské rozhrania, ktoré zobrazujú krátky zoznam odporúčaní.

Žiadna z týchto metrík sama osebe nie je klasická presnosť trojtriedneho klasifikátora. V tomto projekte model produkuje rankingové skóre a graded nDCG zachytáva rozdiel core–contextual nepriamo cez poradie.

6.2 Experimentálny protokol

Po výbere mean alias reprezentácie sa v notebooku `06_finetune_selected_models.ipynb` fine-tunujú tri vybrané modely. Použijú sa iba pozitívne páry s `label > 0`; labels 1 a 2 sú teda počas fine-tuningu považované za rovnocenné pozitívne páry. Nastavenia experimentu sú:

Loss	`MultipleNegativesRankingLoss`
Počet epoch	2
Batch size	128
Learning rate	$2 \cdot 10^{-5}$
Seed	42

Pri tomto loss je správna skill partnerom názvu pozície a ostatné skills z batchu slúžia ako in-batch negatives. Sampler `NO_DUPLICATES` odstraňuje presné opakovanie textov v batchi, ale neodstraňuje sémanticky podobné false negatives. Keďže jedna skill môže byť relevantná pre viac súvisiacich pozícií, ide o dôležité obmedzenie. Tréningový dataset používa stĺpce `anchor` a `positive`; tieto stĺpce sú v konfigurácii Sentence Transformers odovzdané priamo do zodpovedajúcich rout modelu JobBERT. Použité routy sú teda `anchor` a `positive`, pričom mapovanie je `router_mapping={änchor": änchor", "positive": "positive"}`. Nepoužívajú sa routy `query` a `document`.

Rozdelenie internej validácie sa robí na úrovni názvu pozície, nie náhodným rozdelením jednotlivých riadkov. Tak sa znižuje riziko, že sa rovnaká pozícia objaví v tréningu aj internej validácii. Finálna evaluácia sa však vykonáva jednotným protokolom na celom development sete v notebooku `07_final_comparison_and_error_analysis.ipynb`.

Notebook 07 porovnáva osem systémov: päť zero-shot systémov a tri fine-tunované systémy. Okrem agregovaných metrík vytvára výsledky po jednotlivých pozíciách pre všetkých 304 queries, súbor s najťažšími pozíciami a AUC analýzu rozlíšenia relevantných položiek a core položiek.

7 Výsledky

Ako autoritatívny zdroj agregovaných výsledkov používame súbor `results/final_system_comparison.c` ktorý vznikol vo finálnom porovnávacom notebooku. V tabuľke je preto pre zero-shot JobBERT uvedené $MRR = 0{,}7886$. Samostatný export error analysis dopočítava metriky z per-job tabuliek a uvádza približne 0,7903; tento rozdiel je dôsledkom odlišného zdroja agregácie, nie zmeny modelu. Fine-tuned JobBERT má v oboch výstupoch $MRR = 0{,}7997$. Pre porovnateľnosť sú všetky čísla v tabuľke prebraté z jedného autoritatívneho CSV.

JobBERT bez fine-tuningu dosahuje najlepší graded nDCG a MAP. Tento výsledok je konzistentný s možným prínosom doménovej špecializácie v tejto úlohe, nepredstavuje však test štatistickej významnosti. Fine-tuning E5 zvyšuje nDCG z 0,6401 na 0,7040 a MPNet z 0,6327 na 0,6981. Pri JobBERT sa celkový graded nDCG mierne zníži, ale zlepší sa MRR a všetky sledované Precision@K. To znamená, že fine-tuned JobBERT častejšie umiestni relevantnú zručnosť úplne na začiatok, hoci celé graded poradie je podľa nDCG o niečo

Tabuľka 2: Hlavné výsledky na development sete; vyššia hodnota je lepšia.

Fáza	Model	nDCG	MAP	MRR	P@1	P@5	P@10
Zero-shot	JobBERT	0.7381	0.3416	0.7886	0.6480	0.5625	0.5178
Fine-tuned	JobBERT	0.7319	0.3258	**0.7997**	**0.6678**	**0.5882**	**0.5507**
Fine-tuned	E5	0.7040	0.2694	0.7243	0.5658	0.5138	0.5039
Fine-tuned	MPNet	0.6981	0.2602	0.7071	0.5625	0.5033	0.4766
Zero-shot	E5	0.6401	0.1642	0.6958	0.5428	0.4507	0.4168
Zero-shot	MPNet	0.6327	0.1612	0.6302	0.4539	0.3980	0.3711
Zero-shot	BGE	0.6309	0.1555	0.6340	0.4441	0.4138	0.3737
Zero-shot	MiniLM	0.6213	0.1476	0.6348	0.4704	0.3836	0.3655

slabšie. Podľa tejto konfigurácie teda fine-tuning zlepšil reportované retrieval metriky pre E5 a MPNet a top-k metriky pre JobBERT, zatiaľ čo zero-shot JobBERT zostal najsilnejší podľa graded nDCG. Štatistické testy významnosti neboli vykonané.

Notebook 07 uvádza aj AUC výsledky. Zero-shot JobBERT dosahuje približne 0,9596 pre rozlíšenie relevantných a irelevantných zručností a 0,9585 pre preferenciu core voči contextual. Fine-tuned JobBERT dosahuje 0,9420, respektíve 0,9483. Tieto výsledky podporujú hlavný záver pre dostupné qrels: modely dobre oddeľujú posudzované relevantné skills od nepozitívnych alebo nehodnotených kandidátov. Tieto hodnoty však nie sú dôkazom, že každý kandidát bez qrels je skutočne irelevantný, a AUC nie je presnosť trojtriedneho klasifikátora. Rozdiel medzi core a contextual je jemnejší a v tomto projekte sa nepredikuje samostatnou classification head.

8 Možné rozšírenia

Nasledujúce návrhy nie sú súčasťou implementovaného pipeline:

- graded alebo pairwise ranking loss, ktorý by počas tréningu rozlišoval grade 2 od grade 1;
- filtrovanie false negatives pri in-batch negatívoch;
- explicitný klasifikátor pre core a contextual labels;
- kvalitnejšie alebo manuálne overené negatívne vzorky;
- intervaly spoľahlivosti a párové testy štatistickej významnosti.

9 Použitie AI a reprodukovateľnosť

9.1 Použitie LLM a AI agentov

Počas projektu boli LLM použité ako podporný nástroj pri návrhu pipeline, písaní prvých verzií kódu, interpretácii chýb a kontrole dokumentácie. Experimenty a výsledky však vznikli lokálnym spustením notebookov členmi tímu. LLM nebola zdrojom nameraných metrík. Vývojový záznam v súbore `llm.md` uvádza použité nástroje, etapy práce, overovanie výstupov aj zistené chyby. Každý návrh vygenerovaný LLM bol preto potrebné skontrolovať voči kódu, dátam a skutočnému výstupu experimentu.

9.2 Postup reprodukcie

Reprodukciu možno vykonať nasledovne:

1. naklonovať repozitár a spustiť terminál v jeho koreňovom adresári;
2. vytvoriť kompatibilné Python prostredie;
3. nainštalovať závislosti príkazom `pip install -r requirements.txt`;
4. skontrolovať, že `config.py` obsahuje `RANDOM_SEED = 42`;
5. spustiť `data_processing.ipynb`, ktorý vytvorí `data/processed/train.csv` a `data/processed/t`
6. spustiť `04_five_model_comparison.ipynb`, ktorý vytvorí porovnanie 15 konfigurácií;
7. spustiť `05_locked_model_comparison.ipynb`, ktorý vyberie globálnu reprezentáciu aliasov a kandidátov na fine-tuning;
8. spustiť `06_finetune_selected_models.ipynb`; notebook stiahne základné modely a uloží lokálne fine-tuned váhy;
9. spustiť `07_final_comparison_and_error_analysis.ipynb`, ktorý vytvorí finálne tabuľky, per-job analýzu a export najťažších pozícií.

Notebooky 04–07 tvoria finálnu metodiku tejto práce. Staršie notebooky 01–03 zostávajú v repozitári ako vývojová história, ale nie sú súčasťou definície finálneho experimentálneho protokolu. Výsledky sa ukladajú do adresára `results/`; kontrolnými výstupmi sú najmä `final_system_comparison.csv`, `error_analysis_summary.csv` a `error_analysis_per_job.csv`.

10 Záver

Navrhli a experimentálne sme overili zdokumentovaný experimentálny postup pre vyhľadávanie ESCO zručností podľa názvu pracovnej pozície. Pipeline porovnáva päť sentence-embedding modelov, tri stratégie reprezentácie aliasov a kontrastívny fine-tuning troch vybraných modelov. Hlavným výsledkom je, že doménový JobBERT bez fine-tuningu dosahuje najlepší celkový graded ranking ($nDCG = 0{,}7381$), zatiaľ čo fine-tuned JobBERT poskytuje najlepšie top-k výsledky.

Fine-tuning všeobecných modelov E5 a MPNet prináša zlepšenie v použitej konfigurácii, zatiaľ čo pri JobBERT zvyšuje najmä top-k metriky. Súčasne výsledky ukazujú, že retrieval a klasifikácia typu zručnosti nie sú totožné problémy. Systém pracuje s graded rankingom a neobsahuje samostatný klasifikátor pre core a contextual labels.

Literatúra

[1] W. Veys, L. Gasco, M. De Lange a J.-J. Decorte, "Overview of TalentCLEF 2026: Task B – Job-Skill Matching with Skill Type Classification", in *CLEF (Working Notes)*, 2026.

[2] L. Gasco et al., “Overview of the TalentCLEF 2026: Skill and Job Title Intelligence for Human Capital Management”, in *Experimental IR Meets Multilinguality, Multimodality, and Interaction*, ed. Lecture Notes in Computer Science, zv. 17087, Cham: Springer Nature Switzerland, 2026.

[3] S. A. Ibrahim a W. Zaghouani, “MARSAD at TalentCLEF 2026 Task B: Hybrid ESCO-Aware Retrieval for Job–Skill Matching”, 2026. URL: https://api.semanticscholar.org/CorpusID:292667278

[4] I. Q. Luthfiyyah, S. B. Yudhoatmojo a I. Budi, “ui-nlp at TalentCLEF 2026: Multilingual Bi-Encoder Retrieval with Ensemble Strategy for Job-Person and Job-Skill Matching”, 2026. URL: https://api.semanticscholar.org/CorpusID:292667631