Zhoda pracovných pozícií a zručností

Semantické vyhľadávanie a hodnotenie typov zručností v úlohe TalentCLEF 2026 Task B

Danil Kozhan, Valeriia Nikolaeva, Anatolii Vasylov, Dmytro Skrypchenko

25. október 2026

Abstrakt

Táto práca sa zaoberá úlohou TalentCLEF 2026 Task B, ktorej cieľom je vyhľadať zručnosti relevantné pre názov pracovnej pozície a zoradiť ich podľa relevantnosti. Zároveň úloha rozlišuje medzi základnými zručnosťami (*core*) a kontextovými zručnosťami (*contextual*). Navrhli sme reprodukovateľný experimentálny pipeline založený na sentence-embedding modeloch, kosínovej podobnosti, reprezentácii ESCO zručností pomocou aliasov a kontrastívnom fine-tuningu vybraných modelov. Porovnali sme päť predtrénovaných modelov a tri stratégie spracovania aliasov. Najlepší výsledok podľa graded nDCG dosiahol model `TechWolf/JobBERT-v2` bez fine-tuningu, pri priemerovaní embeddingov všetkých aliasov zručnosti ($nDCG = 0{,}7381$). Fine-tuning zlepšil všeobecné modely E5 a MPNet, zatiaľ čo pri JobBERT zlepšil najmä presnosť v horných pozíciách. Podľa dostupných qrels modely lepšie oddeľujú posudzované relevantné položky od nepozitívnych alebo nehodnotených kandidátov než zoradia základné a kontextové zručnosti.

Kľúčové slová: spracovanie prirodzeného jazyka, sentence embeddings, ESCO, vyhľadávanie zručností, ranking, TalentCLEF, JobBERT

1 Problém, motivácia a ciele

Digitálne pracovné portály, nástroje na odporúčanie pracovných ponúk a systémy na analýzu trhu práce potrebujú prepájať neštruktúrovaný text pracovných ponúk s jednotným opisom profesií a zručností. Rovnaká zručnosť môže byť v texte vyjadrená rôznymi synonymami a názov pracovnej pozície často neposkytuje dostatočne podrobný zoznam požiadaviek. Ručné mapovanie pozícií na zručnosti je časovo náročné, ťažko škálovateľné a môže byť nekonzistentné medzi anotátormi alebo organizáciami.

TalentCLEF 2026 Task B formalizuje tento problém ako vyhľadávanie zručností pre názov pracovnej pozície a klasifikáciu typu nájdenej zručnosti (**talentclef2026overviewb**). V kontexte úlohy je základná zručnosť potrebná na výkon práce bez ohľadu na konkrétneho zamestnávateľa alebo pracovné prostredie. Kontextová zručnosť závisí viac od organizácie, odvetvia alebo projektu a má preto voliteľnejší charakter.

Motiváciou projektu je vytvoriť systém, ktorý:

1. automaticky vyhľadá zručnosti relevantné pre názov pozície;
2. využije normalizovaný slovník ESCO namiesto voľného generovania názvov;

3. zoradí zručnosti tak, aby sa relevantné položky nachádzali na začiatku;

4. vyhodnotí rozdiel medzi základnou a kontextovou relevanciou prostredníctvom graded rankingu;

5. bude reprodukovateľný a vyhodnotený na oficiálnom development formáte.

Projekt skúma tieto výskumné otázky:

VO1: Ako dobre dokážu predtrénované sentence-embedding modely vyhľadávať ESCO zručnosti pre názov pozície?

VO2: Zlepšuje doménová špecializácia modelu výsledky oproti všeobecným embedding modelom?

VO3: Pomáha pri reprezentácii zručnosti použiť všetky jej aliasy?

VO4: Zlepšuje kontrastívny fine-tuning vybraných modelov retrieval?

VO5: Sú modely úspešnejšie pri rozlíšení relevantnej a irelevantnej zručnosti než pri zoradení základných a kontextových zručností?

2 Súvisiaca práca

2.1 TalentCLEF a ESCO

TalentCLEF rozširuje klasické úlohy informačného vyhľadávania o doménu ľudského kapitálu a pracovných zručností. Prehľad súťaže opisuje spoločné úlohy, dáta a hodnotenie a zdôrazňuje potrebu normalizovaných znalostí o pracovných pozíciách a zručnostiach (**gasco2026overview**). Špecifický prehľad Task B definuje párovanie názvov pozícií so zručnosťami a graded relevanciu, v ktorej sa rozlišujú základné a kontextové zručnosti (**talentclef2026overviewb**).

ESCO predstavuje európsku viacjazyčnú klasifikáciu zručností, kompetencií, kvalifikácií a povolaní. V tomto projekte sa využívajú ESCO identifikátory a textové termíny zručností. Identifikátor umožňuje, aby sa synonymné alebo alternatívne pomenovania spájali s jednou normalizovanou položkou.

2.2 Prístupy účastníkov

Predchádzajúce riešenia v rámci TalentCLEF kombinujú lexikálne, neurónové a hybridné retrieval metódy. Práca MARSAD opisuje ESCO-aware hybridné vyhľadávanie, v ktorom sa kombinuje informácia zo štruktúry ESCO a textová podobnosť (**IbrahimMARSADAT**). Tento smer je relevantný pre náš projekt, pretože ukazuje, že samotná povrchová podobnosť nemusí zachytiť vzťahy medzi pozíciami a zručnosťami.

Tím ui-nlp používa bi-encoder retrieval a ensemble stratégie pre úlohy job-person a job-skill matching (**LuthfiyyahuinlpAT**). Bi-encoder prístup je blízky nášmu pipeline: dotazy a kandidátne dokumenty sa kódujú samostatne a následne sa porovnávajú vo vektorovom priestore. Výhodou je škálovateľnosť na tisíce kandidátnych zručností; nevýhodou je, že samostatné embeddingy nemusia zachytiť všetky jemné interakcie medzi dvojicou textov.

Naše riešenie preto používa sentence embeddings ako transparentný a reprodukovateľný baseline. Rozširuje ho porovnaním doménového modelu JobBERT, všeobecných modelov

a kontrastívneho fine-tuningu. Nejde o generovanie nových zručností: všetky výsledky sa vyberajú z poskytnutého ESCO-normalizovaného corpus.

3 Dáta

3.1 Pôvod a formát

Použité dáta pochádzajú z adresára `data/raw/TaskB`. Tréningová časť obsahuje vzťahy medzi povolaniami a zručnosťami odvodené z ESCO a dve mapovania identifikátorov na textové termíny. Development časť obsahuje dotazy, úplný slovník kandidátnych zručností a súbor qrels s anotovanou relevanciou.

V tejto práci používame nasledujúce pojmy:

Povolanie (occupation): identifikované ESCO URI alebo tréningovým `job_id`; jeho textové pomenovanie je názov pozície.

Zručnosť (skill): ESCO položka identifikovaná URI alebo `skill_id`.

Alias: alternatívny textový názov tej istej ESCO zručnosti.

Query: názov pracovnej pozície, pre ktorú sa vyhľadávajú zručnosti.

Corpus item: kandidátna ESCO zručnosť, ktorú možno zaradiť do výsledného zoznamu.

Qrel: judgment vzťahu query–corpus item. Obsahuje query ID, corpus ID a graded relevanciu.

Tabuľka 1: Počty záznamov v použitých dátových súboroch.

Súbor	Počet	Význam
`training/job2skill.tsv`	114 699	tréningové väzby povolanie–zručnosť
`training/jobid2terms.json`	3 039	top-level identifikátory povolaní
`training/skillid2terms.json`	13 939	top-level identifikátory zručností
`validation/queries`	304	development query názvov pozícií
`validation/corpus_elements`	9 052	kandidátne ESCO zručnosti
`validation/qrels.tsv`	56 418	anotované query–skill judgments
`processed/train.csv`	164 699	páry po pridaní vzorkovaných negatívov
`processed/test.csv`	96 418	lokálny validation-derived súbor

Počty v tabuľke predstavujú fyzické dátové záznamy. JSON súbory obsahujú 3 039, respektíve 13 939 top-level identifikátorov; po spojení s tréningovým mappingom môže byť počet aktívne prepojených identifikátorov menší, čo však nie je alternatívna definícia počtov uvedených v tabuľke. Pri súboroch TSV `job2skill.tsv` a `qrels.tsv` nejde o riadok s hlavičkou. Pri spracovaní sa k pozitívnym riadkom pridajú textové názvy a následne sa do CSV doplnia syntetické negatívy. Preto má `processed/train.csv` $114\,699 + 50\,000 = 164\,699$ dátových riadkov a `processed/test.csv` $56\,418 + 40\,000 = 96\,418$ dátových riadkov; CSV hlavička sa do týchto počtov nezapočítava. Qrels explicitne obsahuje grade 2 pre core zručnosti a grade 1 pre contextual zručnosti. Kandidátne skills, ktoré v qrels chýbajú, dostávajú pri evaluácii grade 0. V qrels je 16 161 záznamov grade 2 a 40 257 záznamov grade 1.

3.2 Licencia a redistribúcia

V pracovnom priestore nie je pri dátových súboroch priložený samostatný licenčný súbor, ktorý by udeľoval všeobecné právo na redistribúciu. Dáta preto neinterpretujeme ako voľne redistribuovateľný dataset. Použitie ESCO údajov a materiálov TalentCLEF musí rešpektovať podmienky organizátorov, podmienky zdroja ESCO a prípadné podmienky konkrétneho kurzu alebo súťaže. Táto správa opisuje lokálny experiment; pred zverejnením dát alebo modelových artefaktov je potrebné overiť aktuálne licenčné a redistribučné pravidlá.

4 Predspracovanie dát

Implementácia predspracovania je v notebooku `data_processing.ipynb`. Na začiatku sa načíta `job2skill.tsv`, mapovanie `jobid2terms.json` a mapovanie `skillid2terms.json`. Z každého zoznamu termínov sa pre lokálny spracovaný súbor vyberie prvý termín ako `job_name`, respektíve `skill_name`. Následne sa obe mapovania spoja s tabuľkou väzieb podľa identifikátorov.

Pôvodné označenia tréningových väzieb sú:

Pôvodné označenie	**Číselný label**	**Interpretácia**
`essential`	2	základná zručnosť
`optional`	1	kontextová/voliteľná zručnosť
`irrelevant`	0	irelevantná dvojica

4.1 Vzorkovanie negatívnych párov

Tréningové mapovanie obsahuje iba známe pozitívne väzby, preto notebook vytvára 50 000 negatívnych párov. Náhodne sa vyberajú povolania a zručnosti zo zoznamov identifikátorov. Dvojica sa prijme iba vtedy, ak sa nenachádza v množine známych pozitívnych dvojíc. Proces opakuje bloky 1 000 náhodných výberov, až kým nevznikne 50 000 unikátnych kandidátov. Seed je nastavený na hodnotu 42 v súbore `config.py`. Páry sa následne spoja s textami a dostanú label 0.

Takto vytvorené negatívy sú *assumed negatives*: ide o dvojice, ktoré nie sú v poskytnutom mappingu, nie o manuálne overené negatívne anotácie. Neprítomnosť väzby preto nemusí znamenať, že zručnosť je v realite pre dané povolanie nesprávna. Toto obmedzenie je dôležité pri interpretácii modelov, ktoré by tieto negatívy používali ako učebné príklady.

Pre validation-derived `test.csv` sa rovnakým postupom pridá 40 000 náhodných negatívnych párov k oficiálnym qrels z development časti. Tento lokálny súbor nie je skrytý oficiálny test súťaže a nepoužíva sa ako hlavný ranking benchmark. Hlavné experimenty pracujú priamo s 304 development queries, úplným corpusom 9 052 skills a qrels.

5 Finálna metodika a experimentálny pipeline

5.1 Spoločný ranking pipeline

Finálny experimentálny pipeline je implementovaný v tomto poradí:

1. `data_processing.ipynb`: príprava tréningových a validation-derived tabuliek;

2. `04_five_model_comparison.ipynb`: porovnanie piatich modelov a troch aliasových stratégií;
3. `05_locked_model_comparison.ipynb`: uzamknutie mean reprezentácie a výber modelov na fine-tuning;
4. `06_finetune_selected_models.ipynb`: fine-tuning JobBERT, E5 a MPNet;
5. `07_final_comparison_and_error_analysis.ipynb`: finálne porovnanie a error analysis.

Spoločný ranking postup v notebookoch 04–07 pozostáva z týchto krokov:

1. načítanie development queries, corpus elements a qrels;
2. zakódovanie názvov pozícií a textov skill aliasov sentence-embedding modelom;
3. vytvorenie reprezentácie každej skill;
4. výpočet kosínovej podobnosti medzi query embeddingom a každou kandidátnou skill;
5. zoradenie všetkých 9 052 kandidátov pre každú z 304 pozícií;
6. porovnanie výsledného poradia s qrels.

Embeddings sa normalizujú, takže kosínová podobnosť je v implementácii ekvivalentná skalárnemu súčinu. Modely neprodukujú nové názvy skills; skóre určuje iba poradie položiek v poskytnutom gazetteer.

5.2 Porovnávané modely

Notebook `04_five_model_comparison.ipynb` porovnáva:

- `all-MiniLM-L6-v2`;
- `all-mpnet-base-v2`;
- `TechWolf/JobBERT-v2`;
- `BAAI/bge-base-en-v1.5`;
- `intfloat/e5-base-v2`.

Pre každú zručnosť sa testujú tri reprezentácie:

first: použije sa iba prvý alias;

mean: embeddingy všetkých aliasov sa spriemerujú a výsledný vektor sa znovu normalizuje;

max: skóre zručnosti je maximum kosínovej podobnosti cez všetky jej aliasy.

Notebook 05 následne *uzamkne* globálnu stratégiu aliasov. Kritériom je priemerný graded nDCG cez všetkých päť modelov; pri zhode sa použije MAP. Výsledkom je stratégia `mean`: 0,6526 oproti 0,6502 pre `first` a 0,6426 pre `max`. Na základe poradia modelov pri uzamknutej reprezentácii sa na fine-tuning vyberú JobBERT, E5 a MPNet.

Rozsah implementovanej úlohy. Projekt implementuje retrieval s graded relevanciou, nie samostatný trojtriedny klasifikátor. Grade 2 označuje core/essential skill, grade 1 contextual/optional skill a kandidát bez záznamu v qrels dostáva pri evaluácii grade 0. Fine-tuning používa labels 1 a 2 ako pozitívne páry. Rozlíšenie core a contextual sa preto vyhodnocuje nepriamo poradím prostredníctvom graded nDCG. Samostatná classification head, ktorá by predikovala core, contextual, complementary alebo transversal triedu, implementovaná nie je. Širšie termíny complementary a transversal sa v tomto projekte nepoužívajú ako samostatné labely.

5.3 Reprodukovateľnosť baseline

Projekt poskytuje zdokumentovaný a reprodukovateľný experimentálny postup. Presná numerická reprodukcia však nemusí byť za každých okolností identická v dôsledku verzií softvéru, použitého hardvéru, konfigurácie CUDA, nondeterministického tréningu a opätovného sťahovania modelov. Lokálne fine-tuned checkpointy nie sú súčasťou repozitára. Experimenty používajú `RANDOM_SEED = 42`. Závislosti sú uvedené v `requirements.txt`: `pandas`, `numpy`, `scikit-learn`, `sentence-transformers`, `jupyter`, `datasets`, `accelerate` a `matplotlib`; ich verzie však nie sú úplne pripnuté. Predtrénované modely sa pri prvom spustení načítajú z Hugging Face. Notebooky je potrebné spúšťať z koreňa repozitára, aby relatívne cesty k dátam fungovali.

6 Metriky a experimentálne nastavenie

6.1 Metriky

Implementácia metrík je v súbore `ranking_metrics.py`. Pre každý query sa najprv vytvorí stabilné poradie podľa klesajúceho skóre. Stabilné triedenie zabezpečuje deterministické správanie pri zhodných skóre.

Graded nDCG. Hlavná metrika *graded nDCG* používa zisky 2 pre základné a 1 pre kontextové zručnosti. Diskontovanie podľa pozície znamená, že relevantná zručnosť na začiatku zoznamu je cennejšia než rovnaká zručnosť na jeho konci:

$$DCG = \sum_{i=1}^{n} \frac{rel_i}{\log_2(i+1)}, \qquad nDCG = \frac{DCG}{IDCG}.$$

Táto metrika je vhodná, pretože zohľadňuje retrieval aj rozdiel medzi core a contextual.

Binary nDCG a MAP. Pri binárnych metrikách sa labels 1 a 2 zlúčia do hodnoty relevantné. MAP meria, ako kompaktne sú všetky relevantné položky umiestnené v poradí, nie iba prvá nájdená položka. Binary nDCG a MAP preto hodnotia schopnosť odfiltrovať irelevantné zručnosti.

MRR a Precision@K. MRR používa recipročnú pozíciu prvej relevantnej zručnosti. Precision@1, Precision@5 a Precision@10 merajú priemerný podiel relevantných zručností v horných K pozíciách. Sú praktické pre používateľské rozhrania, ktoré zobrazujú krátky zoznam odporúčaní.

Žiadna z týchto metrík sama osebe nie je klasická presnosť trojtriedneho klasifikátora. V tomto projekte model produkuje rankingové skóre a graded nDCG zachytáva rozdiel core–contextual nepriamo cez poradie.

6.2 Experimentálny protokol

Po výbere mean alias reprezentácie sa v notebooku `06_finetune_selected_models.ipynb` fine-tunujú tri vybrané modely. Použijú sa iba pozitívne páry s `label > 0`; labels 1 a 2 sú teda počas fine-tuningu považované za rovnocenné pozitívne páry. Nastavenia experimentu sú:

Loss	`MultipleNegativesRankingLoss`
Počet epoch	2
Batch size	128
Learning rate	$2 \cdot 10^{-5}$
Seed	42

Pri tomto loss je správna skill partnerom názvu pozície a ostatné skills z batchu slúžia ako in-batch negatives. Sampler `NO_DUPLICATES` odstraňuje presné opakovanie textov v batchi, ale neodstraňuje sémanticky podobné false negatives. Keďže jedna skill môže byť relevantná pre viac súvisiacich pozícií, ide o dôležité obmedzenie. Tréningový dataset používa stĺpce `anchor` a `positive`; tieto stĺpce sú v konfigurácii Sentence Transformers odovzdané priamo do zodpovedajúcich rout modelu JobBERT. Použité routy sú teda `anchor` a `positive`, pričom mapovanie je `router_mapping={änchor": änchor", "positive": "positive"}`. Nepoužívajú sa routy `query` a `document`.

Rozdelenie internej validácie sa robí na úrovni názvu pozície, nie náhodným rozdelením jednotlivých riadkov. Tak sa znižuje riziko, že sa rovnaká pozícia objaví v tréningu aj internej validácii. Finálna evaluácia sa však vykonáva jednotným protokolom na celom development sete v notebooku `07_final_comparison_and_error_analysis.ipynb`.

Notebook 07 porovnáva osem systémov: päť zero-shot systémov a tri fine-tunované systémy. Okrem agregovaných metrík vytvára výsledky po jednotlivých pozíciách pre všetkých 304 queries, súbor s najťažšími pozíciami a AUC analýzu rozlíšenia relevantných položiek a core položiek.

7 Výsledky

Ako autoritatívny zdroj agregovaných výsledkov používame súbor `results/final_system_comparison.c` ktorý vznikol vo finálnom porovnávacom notebooku. V tabuľke je preto pre zero-shot JobBERT uvedené $MRR = 0{,}7886$. Samostatný export error analysis dopočítava metriky z per-job tabuliek a uvádza približne 0,7903; tento rozdiel je dôsledkom odlišného zdroja agregácie, nie zmeny modelu. Fine-tuned JobBERT má v oboch výstupoch $MRR = 0{,}7997$. Pre porovnateľnosť sú všetky čísla v tabuľke prebraté z jedného autoritatívneho CSV.

JobBERT bez fine-tuningu dosahuje najlepší graded nDCG a MAP. Tento výsledok je konzistentný s možným prínosom doménovej špecializácie v tejto úlohe, nepredstavuje však test štatistickej významnosti. Fine-tuning E5 zvyšuje nDCG z 0,6401 na 0,7040 a MPNet z 0,6327 na 0,6981. Pri JobBERT sa celkový graded nDCG mierne zníži, ale zlepší sa MRR a všetky sledované Precision@K. To znamená, že fine-tuned JobBERT častejšie umiestni relevantnú zručnosť úplne na začiatok, hoci celé graded poradie je podľa nDCG o niečo

Tabuľka 2: Hlavné výsledky na development sete; vyššia hodnota je lepšia.

Fáza	Model	nDCG	MAP	MRR	P@1	P@5	P@10
Zero-shot	JobBERT	0.7381	0.3416	0.7886	0.6480	0.5625	0.5178
Fine-tuned	JobBERT	0.7319	0.3258	**0.7997**	**0.6678**	**0.5882**	**0.5507**
Fine-tuned	E5	0.7040	0.2694	0.7243	0.5658	0.5138	0.5039
Fine-tuned	MPNet	0.6981	0.2602	0.7071	0.5625	0.5033	0.4766
Zero-shot	E5	0.6401	0.1642	0.6958	0.5428	0.4507	0.4168
Zero-shot	MPNet	0.6327	0.1612	0.6302	0.4539	0.3980	0.3711
Zero-shot	BGE	0.6309	0.1555	0.6340	0.4441	0.4138	0.3737
Zero-shot	MiniLM	0.6213	0.1476	0.6348	0.4704	0.3836	0.3655

slabšie. Podľa tejto konfigurácie teda fine-tuning zlepšil reportované retrieval metriky pre E5 a MPNet a top-k metriky pre JobBERT, zatiaľ čo zero-shot JobBERT zostal najsilnejší podľa graded nDCG. Štatistické testy významnosti neboli vykonané.

Notebook 07 uvádza aj AUC výsledky. Zero-shot JobBERT dosahuje približne 0,9596 pre rozlíšenie relevantných a irelevantných zručností a 0,9585 pre preferenciu core voči contextual. Fine-tuned JobBERT dosahuje 0,9420, respektíve 0,9483. Tieto výsledky potvrdzujú hlavný záver pre dostupné qrels: modely dobre oddeľujú posudzované relevantné skills od nepozitívnych alebo nehodnotených kandidátov. Tieto hodnoty však nie sú dôkazom, že každý kandidát bez qrels je skutočne irelevantný, a AUC nie je presnosť trojtriedneho klasifikátora. Rozdiel medzi core a contextual je jemnejší a v tomto projekte sa nepredikuje samostatnou classification head.

8 Možné rozšírenia

Nasledujúce návrhy nie sú súčasťou implementovaného pipeline:

- graded alebo pairwise ranking loss, ktorý by počas tréningu rozlišoval grade 2 od grade 1;
- filtrovanie false negatives pri in-batch negatívoch;
- explicitný klasifikátor pre core a contextual labels;
- kvalitnejšie alebo manuálne overené negatívne vzorky;
- intervaly spoľahlivosti a párové testy štatistickej významnosti.

9 Použitie AI a reprodukovateľnosť

9.1 Použitie LLM a AI agentov

Počas projektu boli LLM použité ako podporný nástroj pri návrhu pipeline, písaní prvých verzií kódu, interpretácii chýb a kontrole dokumentácie. Experimenty a výsledky však vznikli lokálnym spustením notebookov členmi tímu. LLM nebola zdrojom nameraných metrík. Vývojový záznam v súbore `llm.md` uvádza použité nástroje, etapy práce, overovanie výstupov aj zistené chyby. Každý návrh vygenerovaný LLM bol preto potrebné skontrolovať voči kódu, dátam a skutočnému výstupu experimentu.

9.2 Postup reprodukcie

Reprodukciu možno vykonať nasledovne:

1. naklonovať repozitár a spustiť terminál v jeho koreňovom adresári;
2. vytvoriť kompatibilné Python prostredie;
3. nainštalovať závislosti príkazom `pip install -r requirements.txt`;
4. skontrolovať, že `config.py` obsahuje `RANDOM_SEED = 42`;
5. spustiť `data_processing.ipynb`, ktorý vytvorí `data/processed/train.csv` a `data/processed/t`
6. spustiť `04_five_model_comparison.ipynb`, ktorý vytvorí porovnanie 15 konfigurácií;
7. spustiť `05_locked_model_comparison.ipynb`, ktorý vyberie globálnu reprezentáciu aliasov a kandidátov na fine-tuning;
8. spustiť `06_finetune_selected_models.ipynb`; notebook stiahne základné modely a uloží lokálne fine-tuned váhy;
9. spustiť `07_final_comparison_and_error_analysis.ipynb`, ktorý vytvorí finálne tabuľky, per-job analýzu a export najťažších pozícií.

Notebooky 04–07 tvoria finálnu metodiku tejto práce. Staršie notebooky 01–03 zostávajú v repozitári ako vývojová história, ale nie sú súčasťou definície finálneho experimentálneho protokolu. Výsledky sa ukladajú do adresára `results/`; kontrolnými výstupmi sú najmä `final_system_comparison.csv`, `error_analysis_summary.csv` a `error_analysis_per_job.csv`.

10 Záver

Navrhli a experimentálne sme overili zdokumentovaný experimentálny postup pre vyhľadávanie ESCO zručností podľa názvu pracovnej pozície. Pipeline porovnáva päť sentence-embedding modelov, tri stratégie reprezentácie aliasov a kontrastívny fine-tuning troch vybraných modelov. Hlavným výsledkom je, že doménový JobBERT bez fine-tuningu dosahuje najlepší celkový graded ranking ($nDCG = 0{,}7381$), zatiaľ čo fine-tuned JobBERT poskytuje najlepšie top-k výsledky.

Fine-tuning všeobecných modelov E5 a MPNet prináša zlepšenie v použitej konfigurácii, zatiaľ čo pri JobBERT zvyšuje najmä top-k metriky. Súčasne výsledky ukazujú, že retrieval a klasifikácia typu zručnosti nie sú totožné problémy. Systém pracuje s graded rankingom a neobsahuje samostatný klasifikátor pre core a contextual labels.